PONTIFÍCIA UNIVERSIDADE CATÓLICA DO RIO GRANDE DO SUL – PUCRS
ESCOLA POLITÉCNICA – INTRODUÇÃO À VISÃO COMPUTACIONAL
PROFESSORA DANIELA OLIVEIRA FERREIRA DO AMARAL – TRABALHO I

Classificação de Doenças em Folhas de Tomate por Características de Cor, Textura e Forma

Johann Honscha Cibils[1], **Lucas Leuck de Oliveira**[1]

[1]Escola Politécnica – Pontifícia Universidade Católica do Rio Grande do Sul (PUCRS)
Porto Alegre – RS – Brasil

j.honscha@edu.pucrs.br, lucas.oliveira014@edu.pucrs.br

Abstract. *This work classifies tomato leaf diseases from PlantVillage images using only classical Computer Vision, without deep learning. An OpenCV pipeline segments the leaf and lesions and extracts 173 color, texture (GLCM, LBP) and shape (Hu moments) features, classified by SVM, Random Forest and MLP with 5-fold stratified cross-validation on 4,873 images. The best model (SVM-RBF) reached 98.8% accuracy (0.968 macro F1) for healthy vs. diseased and 88.9% (0.891 macro F1) for 10 classes. Errors concentrate on diseases with similar brown lesions. Near-duplicate images and the controlled background limit the conclusions.*

Resumo. *Este trabalho classifica doenças em folhas de tomate a partir de imagens do PlantVillage, usando apenas visão computacional clássica, sem deep learning. Um pipeline em OpenCV segmenta a folha e as lesões e extrai 173 características de cor, textura (GLCM, LBP) e forma (momentos de Hu), classificadas por SVM, Random Forest e MLP com validação cruzada estratificada de 5 partições em 4.873 imagens. O melhor modelo (SVM-RBF) atingiu 98,8% de acurácia (F1 macro 0,968) na tarefa saudável vs. doente e 88,9% (F1 macro 0,891) em 10 classes. Os erros se concentram em doenças com manchas marrons parecidas. Quase duplicatas e o fundo controlado limitam as conclusões.*

1. Introdução

Doenças foliares reduzem a produtividade e a qualidade de culturas como o tomate, e sua identificação precoce depende, em geral, da inspeção visual por pessoas treinadas. Sistemas de visão computacional que reconheçam sintomas a partir de fotografias de folhas são, por isso, uma linha de pesquisa ativa, com potencial de apoiar o diagnóstico em campo.

Grande parte dos trabalhos recentes recorre a redes neurais profundas. Neste trabalho adotamos o caminho oposto, por restrição da disciplina e como exercício metodológico: o problema é resolvido com um pipeline clássico, no qual cada etapa (segmentação, extração de características e classificação) é explícita e pode ser inspecionada. Essa abordagem permite relacionar o desempenho do classificador às características de cor, textura e forma que o alimentam, algo mais difícil em modelos de ponta a ponta.

As contribuições são: (i) um pipeline de visão computacional baseado em OpenCV, com segmentação de folha e de lesões tolerante a sombras no fundo; (ii) um vetor de 173 características de cor, textura e forma; (iii) a comparação de SVM, Random Forest e MLP em duas tarefas, uma binária e uma de 10 classes; e (iv) uma análise dos erros e da importância das características, acompanhada de uma discussão franca das limitações do conjunto de dados.

O restante do artigo está organizado assim: a Seção 2 apresenta trabalhos relacionados; a Seção 3 descreve a metodologia; a Seção 4 detalha o protocolo experimental; a Seção 5 traz os resultados e sua discussão; a Seção 6 trata das limitações; e a Seção 7 conclui.

2. Trabalhos Relacionados

O PlantVillage foi apresentado por Hughes e Salathé [10] como um repositório aberto de imagens de plantas saudáveis e doentes, criado para viabilizar o desenvolvimento de diagnóstico por dispositivos móveis. Mohanty et al. [11] treinaram uma rede convolucional em 54.306 imagens do conjunto, cobrindo 14 culturas e 26 doenças, e relataram 99,35% de acurácia em um conjunto de teste retido. Os mesmos autores mostraram que, ao testar o modelo em imagens obtidas em condições diferentes das de treino, a acurácia caiu para 31,4%, evidenciando a distância entre imagens de laboratório e imagens reais. Barbedo [3] discute, em uma revisão, os principais desafios da identificação automática de doenças em imagens do espectro visível, entre eles a variabilidade das condições de captura e dos sintomas.

Antes das redes profundas, a detecção de doenças em folhas era feita com *pipelines* de processamento de imagens: segmentação, extração de características e classificação. Singh e Misra [15], por exemplo, apresentam um algoritmo de segmentação baseado em algoritmo genético para a detecção e a classificação automática de doenças foliares, além de uma revisão de técnicas de classificação.

Três trabalhos usam, como nós, características manuais em imagens de tomate do PlantVillage. Tan et al. [16] extraíram 157 características (52 de textura, por LBP e GLCM, e 105 de cor, por momentos de cor e histograma) e compararam SVM, kNN e Random Forest com cinco redes profundas. A melhor combinação de características foi cor mais GLCM, e as acurácias dos modelos clássicos foram de 82,1% (kNN), 91,0% (SVM) e 82,7% (Random Forest), contra 91,2% a 99,7% das redes profundas. García Amaro et al. [7] propõem um sistema com segmentação por Otsu ou PCA, descritores de textura (Haralick e LBP) e outros descritores (momentos de Hu, descritores de Fourier, DCT e Gabor), e testam SVM, retropropagação, Naive Bayes, kNN e Random Forest. Al-Shamasneh e Ibrahim [2] relatam 98,80% de acurácia com SVM no tomate do PlantVillage, usando características de textura baseadas em polinômios conformáveis.

Nosso trabalho se diferencia em três pontos. Primeiro, a segmentação da folha usa a distância de cromaticidade ao fundo e remove a sombra, e as lesões são detectadas pela dominância do verde. Segundo, o vetor combina cor, textura e forma da lesão (com momentos de Hu), e analisamos a importância de cada grupo de características. Terceiro, discutimos os erros por classe e as limitações do conjunto de dados.

Em relação aos números, o SVM-RBF obteve 88,9% de acurácia em 10 classes (Tabela 3), próxima dos 91,0% que Tan et al. [16] relatam para o SVM. A comparação exige cautela: eles reorganizaram o conjunto para balancear as classes (com aumento de dados em algumas delas, totalizando 17.859 imagens) e dividiram os dados em 80% para treino e 20% para teste, enquanto usamos 4.873 imagens sem aumento de dados e validação cruzada de 5 partições. Nos dois estudos o SVM foi o melhor entre os modelos clássicos, e doenças de sintomas parecidos se confundem: Tan et al. observam isso entre mancha bacteriana, pinta-preta e mofo-foliar, e nós, principalmente entre pinta-preta e requeima. As redes profundas testadas por eles superaram os modelos clássicos, de

modo que nosso resultado deve ser visto como uma linha de base clássica, e não como o estado da arte.

As características usadas neste trabalho derivam de descritores clássicos: matrizes de co-ocorrência de níveis de cinza (GLCM) [8], padrões binários locais (LBP) [12] e momentos invariantes de Hu [9]. A limiarização automática de Otsu [13] é usada na segmentação, e a classificação emprega SVM [6], Random Forest [5] e uma rede MLP.

3. Metodologia

3.1. Conjunto de dados

Foi utilizada a pasta `color` do PlantVillage disponível no Kaggle [1], restrita à cultura do tomate: 18.160 imagens em 10 classes (nove doenças e a classe saudável). Para manter o tempo de processamento controlado, foram sorteadas até 500 imagens por classe, resultando em 4.873 imagens (a classe *mosaic virus* possui apenas 373). As imagens foram redimensionadas para 256×256 pixels. Para a tarefa binária, as classes de doenças foram agrupadas, resultando em 4.373 imagens doentes e 500 saudáveis.

3.2. Pipeline

A Figura 1 resume o pipeline, implementado em Python com OpenCV [4], scikit-image [17] e scikit-learn [14].

Pré-processamento. A imagem é suavizada com filtro gaussiano 5×5 e convertida para os espaços HSV e Lab, usados nas características de cor, e para tons de cinza, usados nas características de textura. As etapas de segmentação aplicam sua própria suavização gaussiana, descrita a seguir.

Segmentação da folha. O fundo do PlantVillage é uniforme em cada imagem, mas varia de cor entre imagens, e a folha

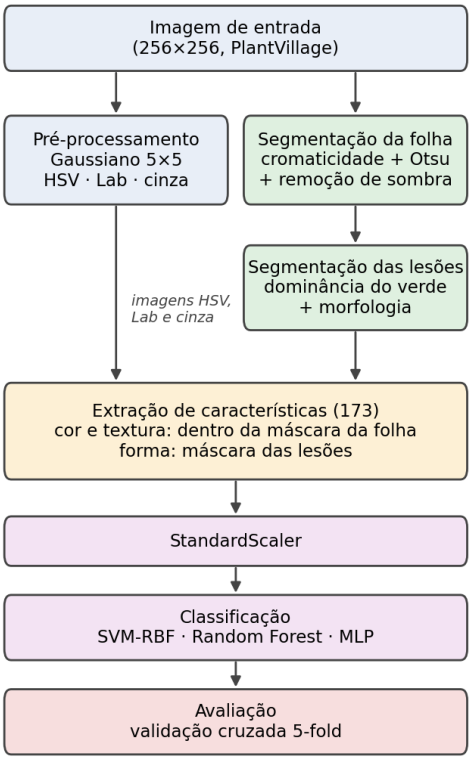


Figura 1. Pipeline de visão computacional proposto.

projeta sombra sobre ele. Uma limiarização simples por saturação mostrou-se inadequada: em testes preliminares, incluía a sombra na máscara e deixava buracos em folhas de baixa saturação. A solução adotada estima a cor do fundo pela mediana dos pixels de uma faixa de 12 pixels nas bordas da imagem e mede, em cada pixel, a distância de cromaticidade até essa cor. Com $\mathbf{c} = (R, G, B)/(R + G + B)$ e $\mathbf{c}_{bg}$ a cromaticidade do fundo,

$$d(p) = \|\mathbf{c}(p) - \mathbf{c}_{bg}\|. \qquad (1)$$

Como a cromaticidade é pouco sensível a variações de brilho, a sombra tem d pequeno e tende a ser excluída. O limiar t é obtido pelo método de Otsu sobre d. Pixels escuros, não verdes e com $d < 1{,}6\,t$ são tratados como sombra residual e removidos. Em seguida aplicam-se fechamento e abertura morfológicos (elemento elíptico 7×7),

e mantém-se o maior contorno externo, preenchido. A Figura 2 mostra a máscara obtida e a folha segmentada.

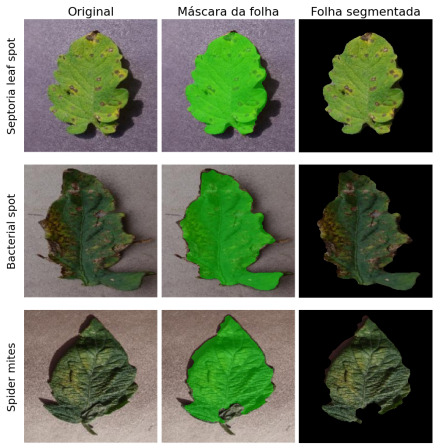


Figura 2. Segmentação da folha: imagem original, máscara da folha e folha segmentada.

Segmentação das lesões. Define-se a dominância do verde $g = (G - R)/(R + G + B)$. Dentro da máscara da folha (erodida com elemento 9×9 para evitar a borda), são consideradas lesão as regiões com $g < 0{,}03$, seguidas de abertura (3×3), fechamento (5×5) e remoção de componentes com menos de 30 pixels. Essa regra usa a relação entre o verde e o vermelho, em vez de uma faixa fixa de matiz, e por isso não confunde o verde escuro das bordas da folha com tecido doente. A Figura 3 mostra as lesões detectadas nas mesmas folhas da Figura 2.

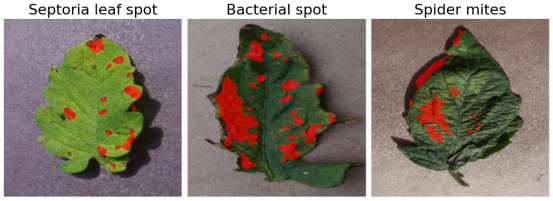


Figura 3. Lesões detectadas (em vermelho) nas mesmas folhas da Figura 2.

Extração de características. Cada imagem é descrita por 173 características (Tabela 1), calculadas dentro da máscara da folha: *cor* (histograma HSV com $8 \times 4 \times 4$ intervalos, além de média e desvio-padrão de cada canal em HSV e Lab); *textura* (propriedades de GLCM: contraste, homogeneidade, energia, correlação e dissimilaridade com 32 níveis, distâncias 1 e 3, e média sobre quatro ângulos; histograma de LBP uniforme com $P = 8$ e $R = 1$); e *forma* (razão área de lesão/área da folha, fração da imagem ocupada pela folha, número de manchas, área média e máxima das manchas, circularidade média e os sete momentos de Hu da máscara de lesão, em escala logarítmica).

Tabela 1. Grupos de características.

Grupo	Descritores	Dim.
Cor	Hist. HSV; média/desvio HSV e Lab	140
Textura	GLCM; LBP uniforme	20
Forma	Lesão e folha (6); momentos de Hu (7)	13
Total		173

3.3. Classificadores

As características são padronizadas (`StandardScaler`) e classificadas por três modelos: SVM com kernel RBF ($C = 10$, γ automático); Random Forest com 300 árvores; e MLP com duas camadas ocultas (128 e 64 neurônios) e parada antecipada. O SVM e o Random Forest usam pesos de classe balanceados. Os hiperparâmetros foram fixados *a priori*, sem busca. Por restrição do trabalho, não foram usadas redes profundas; o MLP é a única rede neural empregada.

4. Protocolo Experimental

A avaliação usa validação cruzada estratificada com 5 partições (embaralhamento com semente 42). Em cada rodada, cerca de 80% das imagens (aproximadamente 3.898) treinam o modelo e 20% (aproximadamente

975) o testam, e cada imagem é testada exatamente uma vez. A padronização é ajustada dentro de cada partição, pois faz parte do *pipeline* do classificador, o que evita vazamento de estatísticas do conjunto de teste. As métricas são acurácia, precisão, revocação e F1 (médias macro) e matrizes de confusão normalizadas por classe, calculadas sobre as predições agregadas das 5 partições.

Como referência, na tarefa binária um classificador que respondesse sempre "doente" acertaria 89,7% (4.373 de 4.873); na tarefa de 10 classes, a acurácia esperada ao acaso é de cerca de 10%.

5. Resultados e Discussão

5.1. Tarefa binária

A Tabela 2 mostra os resultados. O SVM obteve o melhor F1 macro (0,968), com acurácia de 98,8%. Como as classes são desbalanceadas, a acurácia deve ser lida com cautela: a linha de base de 89,7% já é alta. O F1 macro e a revocação da classe saudável são mais informativos. O Random Forest tem a maior precisão na classe saudável (0,98), mas a menor revocação (0,83), ou seja, classifica como doentes muitas folhas saudáveis. O SVM obteve precisão 0,94 e revocação 0,95 nessa classe, e o MLP, 0,95 e 0,92.

Tabela 2. Tarefa binária (saudável *vs.* doente), validação cruzada de 5 partições.

Modelo	Acur.	Prec.	Rev.	F1
SVM-RBF	**0,988**	0,965	**0,972**	**0,968**
MLP	0,986	0,970	0,955	0,963
Random Forest	0,981	**0,981**	0,913	0,944

5.2. Tarefa de 10 classes

A Tabela 3 e a Figura 4 mostram que o desempenho cai de forma consistente na tarefa multiclasse, para cerca de 88–89% de acurácia. O SVM novamente obteve os melhores valores (acurácia 0,889; F1 macro 0,891), mas a diferença para o MLP e o Random Forest é de aproximadamente um ponto percentual. Como não foram calculados desvios-padrão entre as partições nem testes de significância, o resultado é interpretado como desempenho comparável entre os três modelos, com ligeira vantagem do SVM.

Tabela 3. Tarefa de 10 classes de tomate, validação cruzada de 5 partições.

Modelo	Acur.	Prec.	Rev.	F1
SVM-RBF	**0,889**	**0,893**	**0,891**	**0,891**
MLP	0,883	0,885	0,885	0,885
Random Forest	0,876	0,879	0,879	0,878

5.3. Desempenho por classe e análise dos erros

A Tabela 4 detalha o SVM por classe. As melhores são *Yellow Leaf Curl Virus* (F1 0,96), *mosaic virus* (0,95) e saudável (0,95); essas doenças alteram a cor e o padrão da folha inteira, o que é capturado por características globais de cor e textura. As piores são *late blight* (0,80) e *early blight* (0,81), seguidas de *target spot* (0,86) e *Septoria* (0,87).

Tabela 4. SVM-RBF, 10 classes: desempenho por classe.

Classe	Prec.	Rev.	F1
Bacterial spot	0,92	0,92	0,92
Early blight	0,82	0,79	0,81
Late blight	0,75	0,86	0,80
Leaf Mold	0,90	0,88	0,89
Septoria leaf spot	0,89	0,86	0,87
Spider mites	0,89	0,91	0,90
Target Spot	0,88	0,84	0,86
Yellow Leaf Curl Virus	0,97	0,95	0,96
Mosaic virus	0,94	0,95	0,95
Saudável	0,97	0,94	0,95

A matriz de confusão (Figura 5) e a Tabela 5 mostram que os erros não se

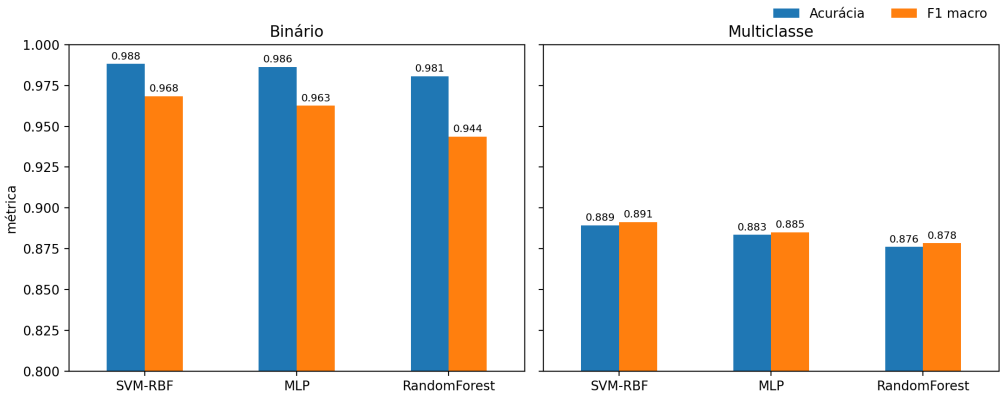


Figura 4. Acurácia e F1 macro dos modelos nas duas tarefas (o eixo vertical começa em 0,8).

distribuem uniformemente. Os oito pares mais frequentes somam 215 imagens, cerca de 40% dos aproximadamente 539 erros do SVM. A classe *late blight* funciona como um "atrator": 121 imagens de quatro outras classes (*early blight*, *leaf mold*, *Septoria* e *target spot*), cerca de 22% de todos os erros, foram rotuladas como *late blight*, o que explica sua precisão baixa (0,75) apesar de revocação razoável (0,86). Há ainda confusão nos dois sentidos entre *early* e *late blight* (45 e 32 imagens).

Tabela 5. Principais confusões do SVM-RBF (classe real → prevista).

Real	Prevista	Imagens
Early blight	Late blight	45
Leaf Mold	Late blight	33
Late blight	Early blight	32
Septoria leaf spot	Late blight	28
Target Spot	Spider mites	25
Early blight	Target Spot	23
Target Spot	Late blight	15
Late blight	Septoria leaf spot	14

Uma hipótese plausível para esses erros é que as doenças fúngicas envolvidas produzem manchas marrons de aparência semelhante, que se distinguem principalmente por detalhes locais (anéis concêntricos, bordas, halos amarelados) que as características globais de cor e textura, calculadas sobre a folha inteira, capturam mal. Esta hipótese não foi testada diretamente neste trabalho; uma análise com características locais por lesão seria o passo natural para verificá-la.

5.4. Importância das características

A análise a seguir se baseia na importância (redução média de impureza) do Random Forest treinado nas 10 classes. Somada por grupo, a importância foi de 60,8% para a cor, 29,2% para a textura e 10,0% para a forma. Como os grupos têm tamanhos diferentes (140, 20 e 13 características), a média por característica é mais informativa: cerca de 0,015 na textura, 0,008 na forma e 0,004 na cor. Assim, a textura é o grupo mais informativo por característica, e a cor concentra a maior parte da importância total principalmente por ter 140 das 173 características. Entre as 15 características mais importantes, oito são bins do histograma LBP, seis são de cor (cinco bins do histograma HSV e o desvio-padrão do matiz) e uma é de forma (`leaf_ratio`, a fração da imagem ocupada pela folha). Os valores de importância individuais são baixos e próximos entre si (o maior é de cerca de 0,026), indicando que a informação está distribuída entre muitas características. Vários dos bins de cor mais importantes pertencem ao primeiro in-

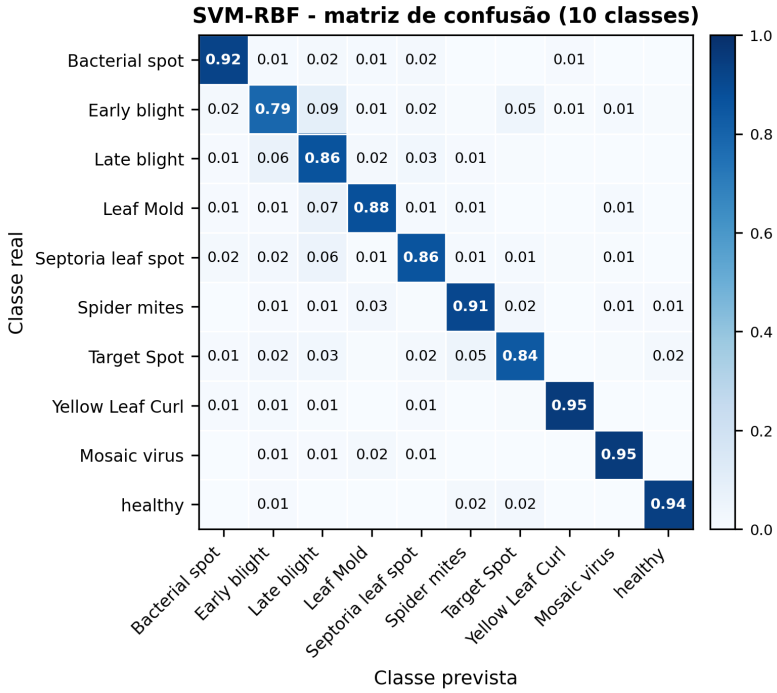


Figura 5. Matriz de confusão normalizada do SVM-RBF (10 classes).

tervalo de matiz do histograma (tons avermelhados e alaranjados), compatível com a descoloração por tecido necrosado. As características de forma da lesão (razão de lesão, número de manchas, momentos de Hu) não aparecem entre as 15 mais importantes, e a forma soma 10,0% da importância, valor próximo da sua parcela de 7,5% das características; ou seja, a geometria das manchas segmentadas não se destacou neste experimento. Cabe ressalvar que a importância por impureza pode favorecer características contínuas e correlacionadas, e que a presença de `leaf_ratio` no topo pode refletir diferenças de enquadramento entre as sessões de captura e não um sinal da doença em si (Seção 6).

5.5. Prova de conceito

O sistema foi implementado em um notebook do Google Colab. Dada uma imagem de folha (do conjunto ou enviada pelo usuário), a aplicação exibe as etapas do pipeline (imagem original, máscara da folha, lesões detectadas) e a classe prevista, tanto pelo modelo binário quanto pelo de 10 classes. O modelo da demonstração foi treinado com todas as 4.873 imagens, portanto ela ilustra o funcionamento e não mede desempenho, que é dado pela validação cruzada. Em fotos sem fundo uniforme, como imagens em close, a segmentação falha e a predição não é confiável (Seção 6).

6. Limitações

Quase duplicatas. O PlantVillage contém imagens muito parecidas, como a mesma folha fotografada em ângulos diferentes ou com ajustes de imagem. A validação cruzada usada aqui sorteia as imagens sem agrupá-las por folha de origem, de modo que imagens quase idênticas podem cair no treino e no teste, e os resultados tendem a ser otimistas. Não foi feita uma validação agrupada por folha.

Fundo controlado. As imagens foram capturadas em laboratório, com fundo uniforme. A segmentação proposta depende disso, pois estima a cor do fundo pelas bordas da imagem. Em fotogra-

fias de campo, com fundo complexo, o método provavelmente não funcionaria sem adaptações. O resultado de 31,4% relatado por Mohanty et al. [11] para imagens de outras fontes sugere que a queda de desempenho fora do laboratório é um risco geral, e não testamos esse cenário.

Segmentação sem referência. Os limiares de segmentação foram definidos empiricamente, com inspeção visual de poucas imagens. Não há máscaras de referência para avaliar quantitativamente a segmentação. Foram observadas falhas pontuais, como pequenos recortes em partes escuras da folha tratadas como sombra. Também ocorre de a borda sombreada da folha ser marcada como lesão (Figura 3, ácaros).

Amostragem e ajuste. Foram usadas 4.873 das 18.160 imagens de tomate, sem ajuste de hiperparâmetros, e sem desvio-padrão ou teste de significância entre os modelos. As diferenças de cerca de um ponto percentual entre os classificadores não devem ser tomadas como conclusivas.

Possível viés de aquisição. A importância elevada de `leaf_ratio` pode indicar que o tamanho ou o enquadramento da folha difere entre classes por razões de coleta. Essa hipótese não foi investigada.

7. Conclusão

Este trabalho mostrou que um pipeline clássico, com segmentação baseada em cromaticidade e características de cor, textura e forma, classifica doenças em folhas de tomate do PlantVillage com 98,8% de acurácia (F1 macro 0,968) na tarefa binária e 88,9% (F1 macro 0,891) em 10 classes, com o SVM-RBF ligeiramente à frente do MLP e do Random Forest. Os erros concentram-se em doenças com manchas marrons semelhantes, sobretudo em torno de *late blight*, e a textura foi o grupo mais informativo por característica, enquanto a geometria das lesões segmentadas não se destacou.

Como trabalhos futuros, destacam-se: validação agrupada por folha, para uma estimativa menos otimista; teste em imagens de campo; características locais por lesão, para separar doenças de aspecto similar; avaliação quantitativa da segmentação com máscaras de referência; e busca de hiperparâmetros com análise de variância entre partições.

Referências

[1] Ali, A. PlantVillage Dataset (Kaggle). Disponível em: `https://www.kaggle.com/datasets/abdallahalidev/plantvillage-dataset`. Acesso em: out. 2026.

[2] Al-Shamasneh, A. R. and Ibrahim, R. W. (2024). Classification of tomato leaf images for detection of plant disease using conformable polynomials image features. *MethodsX*, 13:102844.

[3] Barbedo, J. G. A. (2016). A review on the main challenges in automatic plant disease identification based on visible range images. *Biosystems Engineering*, 144:52–60.

[4] Bradski, G. (2000). The OpenCV Library. *Dr. Dobb's Journal of Software Tools*.

[5] Breiman, L. (2001). Random forests. *Machine Learning*, 45(1):5–32.

[6] Cortes, C. and Vapnik, V. (1995). Support-vector networks. *Machine Learning*, 20(3):273–297.

[7] García Amaro, E., Cervantes Canales, J., Espejel Cabrera, J., Ruiz Castilla, J. S. and García Lamont, F. (2020). Identification of diseases and pests in tomato plants through artificial vision. In *Proceedings of the International*

Conference on Intelligent Computing (ICIC 2020), Lecture Notes in Computer Science, pages 291–301. Springer.

[8] Haralick, R. M., Shanmugam, K. and Dinstein, I. (1973). Textural features for image classification. *IEEE Transactions on Systems, Man, and Cybernetics*, SMC-3(6):610–621.

[9] Hu, M.-K. (1962). Visual pattern recognition by moment invariants. *IRE Transactions on Information Theory*, 8(2):179–187.

[10] Hughes, D. P. and Salathé, M. (2015). An open access repository of images on plant health to enable the development of mobile disease diagnostics. *arXiv:1511.08060*.

[11] Mohanty, S. P., Hughes, D. P. and Salathé, M. (2016). Using deep learning for image-based plant disease detection. *Frontiers in Plant Science*, 7:1419.

[12] Ojala, T., Pietikäinen, M. and Mäenpää, T. (2002). Multiresolution gray-scale and rotation invariant texture classification with local binary patterns. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 24(7):971–987.

[13] Otsu, N. (1979). A threshold selection method from gray-level histograms. *IEEE Transactions on Systems, Man, and Cybernetics*, 9(1):62–66.

[14] Pedregosa, F. et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830.

[15] Singh, V. and Misra, A. K. (2017). Detection of plant leaf diseases using image segmentation and soft computing techniques. *Information Processing in Agriculture*, 4(1):41–49.

[16] Tan, L., Lu, J. and Jiang, H. (2021). Tomato leaf diseases classification based on leaf images: a comparison between classical machine learning and deep learning methods. *AgriEngineering*, 3(3):542–558.

[17] van der Walt, S. et al. (2014). scikit-image: image processing in Python. *PeerJ*, 2:e453.